“智慧中国杯”全国大数据创新应用大赛

用户贷款风险预测

团队：SLaughter

成员：刘祥（队长）张辉 赵纪伟 苏军平 秦剑

1

问题分析

问题描述

数据来源：融360

数据内容：用户基本属性以及银行流水、浏览行为、信用卡账单等记录

根据用户历史信用消费行为及基本属性，预测用户是否会发生逾期行为

问题描述

应用场景

互联网金融贷款逾期预测

难点

数据缺失、验证集选择

直接预测目标

用户是否会发生逾期行为

本质：二分类问题(分类不平衡)

评价指标：KS、AUC

2

算法框架

算法框架

3

数据探索

数据探索

	训练集用户缺失比例	测试集用户缺失比例	训练缺失/预测缺失
用户基本信息	~0%	~0%	——
流水记录	83.3%	94.9%	87.7%
浏览行为	14.7%	13.7%	107.2%
信用卡账单记录	4.4%	1.8%	244.4%

数据缺失严重！！！

数据探索

放款信息

银行流失

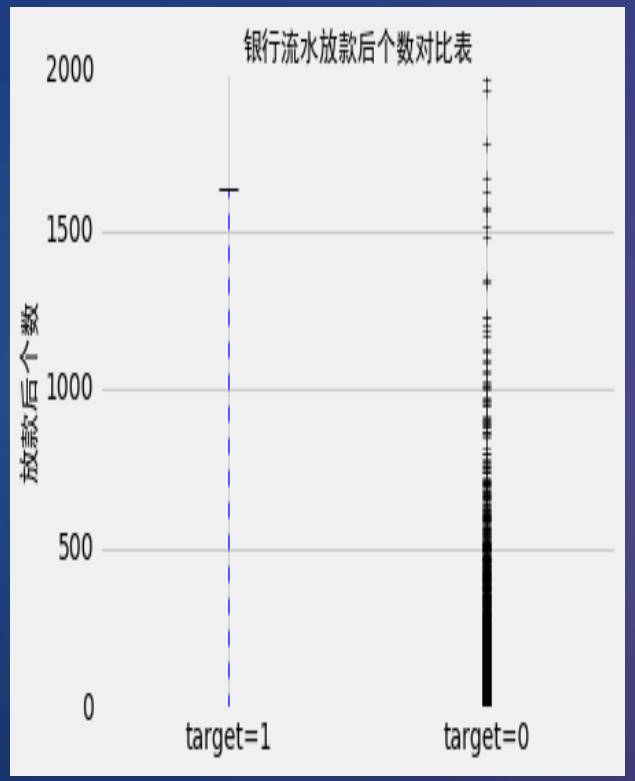

浏览记录

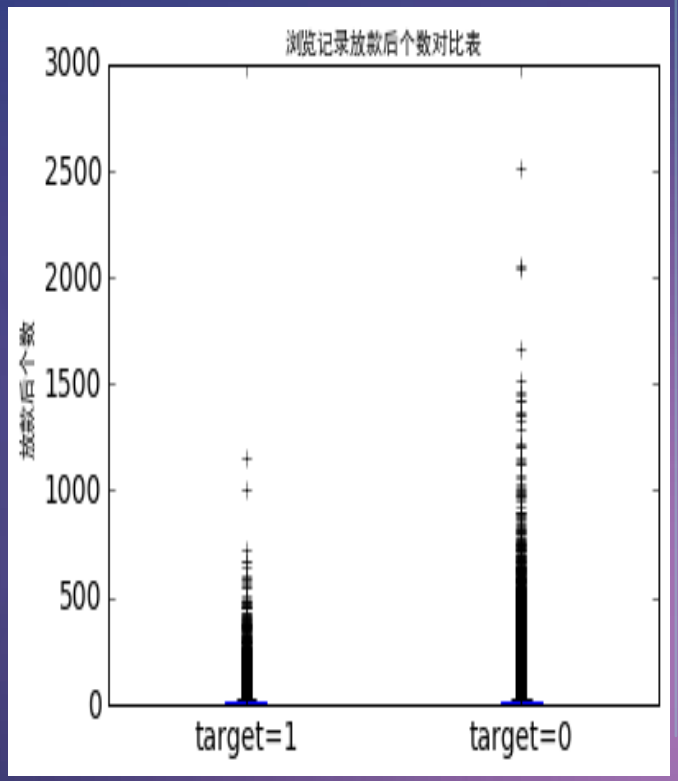

信用卡账单

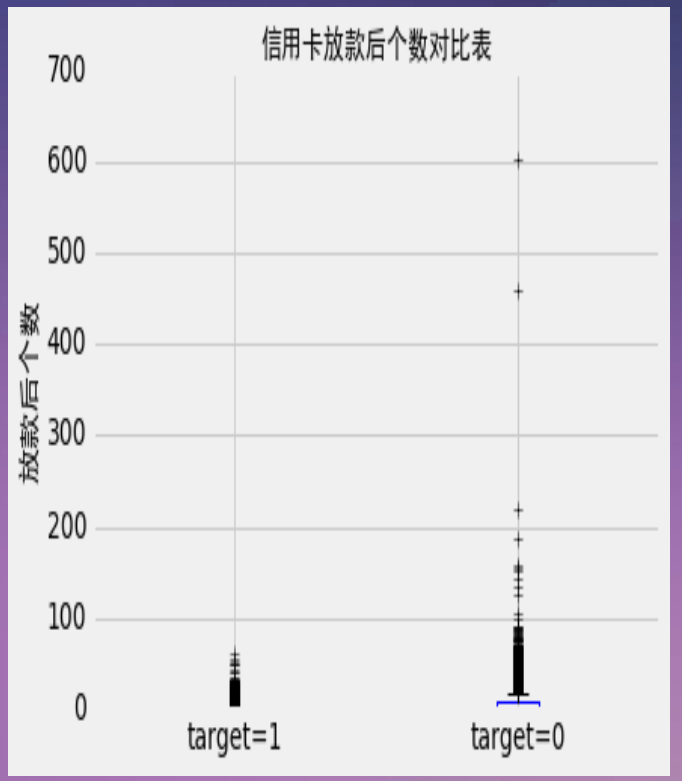

4

特征工程

特征工程

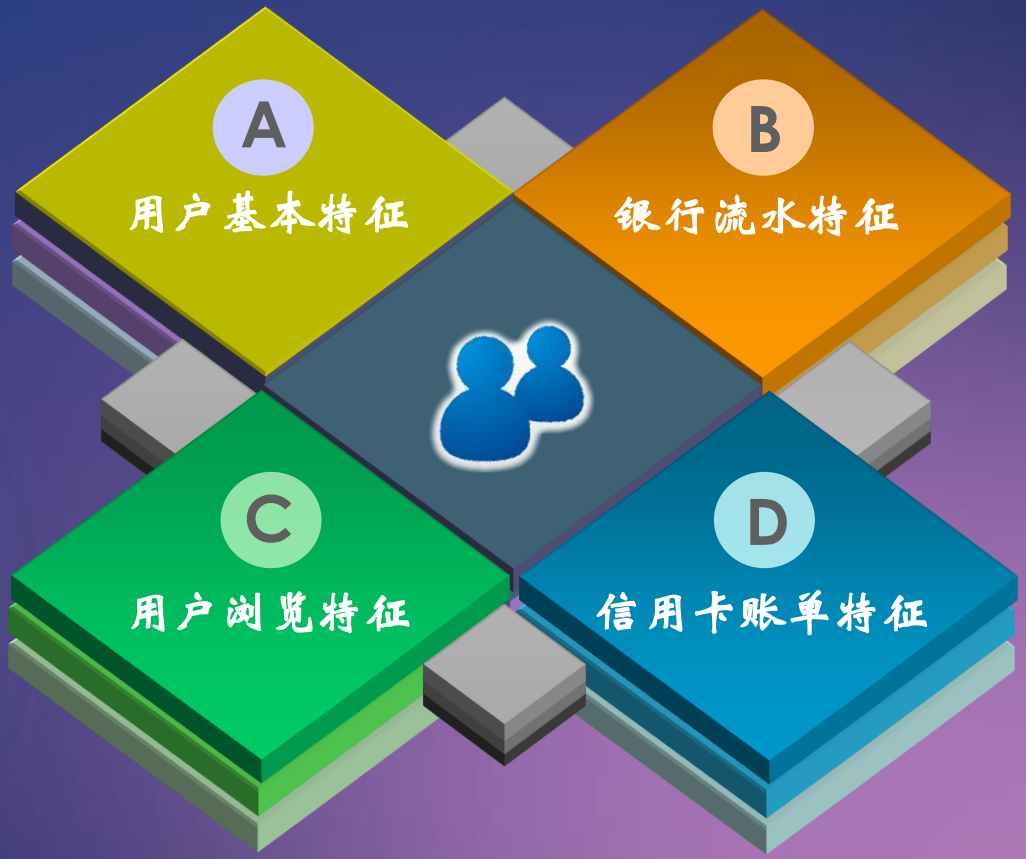

特征工程

用户基本特征

◆ 描述用户的基本属性信息

- 性别,职业,教育程度,婚姻状态,户口类型

银行流水特征

◆ 描述用户的所有银行消费信息

- 账户流通金额，收入，支出，是否工资收入

→ 交易总量、频繁程度，收入支出比，平均每天收入金额

用户浏览行为

◆ 描述用户对本身消费行为的关注情况

- 用户对于自身消费行为的关注程度 → 识别用户的责任意识
- 214种主浏览数据，11种子浏览行为
- 274组浏览数据——浏览行为

特征工程

信用卡消费特征

◆ 描述用户的信用消费状况

统计特征

信用卡记录频率
银行个数
上期账单金额最大值
上期账单金额平均值
上期还款金额最大值
上期还款金额平均值
信用额度最小非零值
……

业务特征

上期账单金额大于上期还款金额的记录个数
总体额度上升or下降
轻度拖欠期数
轻度拖欠金额
重度拖欠期数
重度拖欠金额
重度拖欠期数占比
重度拖欠金额占比
……

特征工程

交叉特征

上期账单金额　　上期还款金额　　信用卡额度　　本期账单余额　　.....

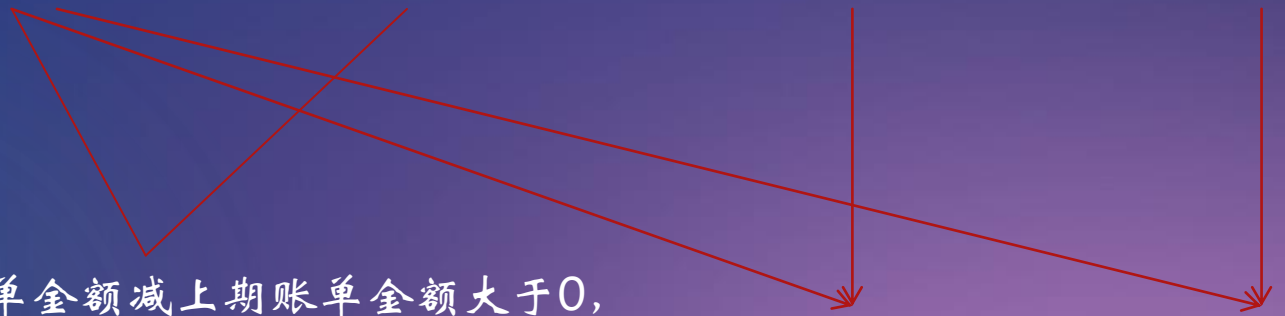

上期账单金额减上期账单金额大于0，小于0个数，等于0个数
上期账单金额大于0同时上期还款金额小于0个数
上期账单金额大于0同时上期还款金额等于0个数
.....
12个交叉特征

构造一个交叉特征群，利用模型特征选择进行特征重要性排序，根据线下结果加入。

特征工程

时间特征

◆ 描述用户的时间信息

统计特征

时间不同的个数
时间未知记录个数
记录的时间跨度
用户最长的卡龄
用户平均卡龄
用户最短卡龄
……

与放款时间交叉

放款前最近时间戳
放款后最近时间戳
时间记录最大值与放款时间差
……

特征工程

放款特征

◆ 描述用户放款前后特征对比

银行流水	浏览记录	信用卡账单
放款前后记录个数	放款前后记录个数	放款前后记录个数
放款前后个数比	放款前一个月记录个数	放款后还款比例
……	……	放款后信用卡支出金额
		……

5

模型融合

模型融合

模型获取

- 对于最终数据，使用两种缺失值处理，两种参数得出XGBoost_A和XGBoost_B
- 使用lightgbm进行5折Bagging预测，得出LightGBM

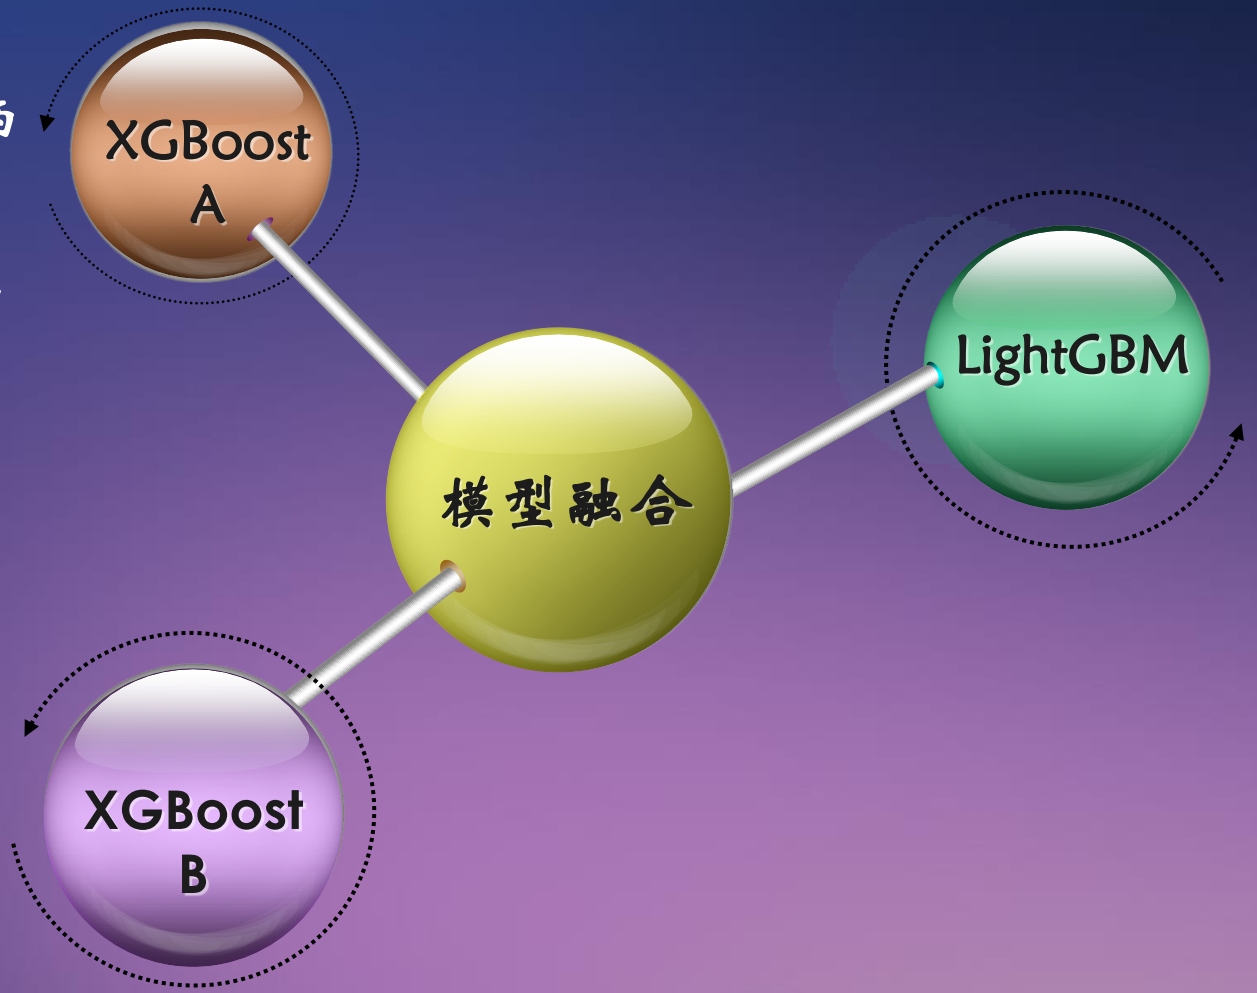

直接加权融合

- 最终结果 KS值0.46702 = 0.05 * XGB_A + 0.20 * LGB + 0.75 * XGB_B

6

总结

总结

融360用户风险预测

- 线下验证 → 没有构造稳定的线下验证
- 模型差异 → 缺少构造多个数据集
- 模型融合 → 缺少模型融合经验

个人能力的提升与团队协作的锻炼

THANKS

请各位专家批评指导！